Actividad 3 — Métodos de aprendizaje supervisado

Descripción de los datos y del modelo

Laura Lorena Forero Romero
Docente: Sandra Bautista | Grupo: 24082026_C1_202634
Corporación Universitaria Iberoamericana

Problema y relación con la actividad anterior

En la actividad 2 calculé rutas con costos conocidos. En esta actividad utilicé aprendizaje supervisado para estimar el tiempo de un viaje a partir de sus características. Desarrollé un componente complementario; no integré la predicción al buscador de rutas ni evalué su uso en una red real.

Fuentes potenciales de datos

Identifiqué como fuentes candidatas el portal de Datos Abiertos Bogotá (https://datosabiertos.bogota.gov.co/), el portal de Datos Abiertos Colombia (https://www.datos.gov.co/) y publicaciones oficiales de TransMilenio (https://www.transmilenio.gov.co/). Podrían aportar información sobre rutas, estaciones u operación, pero es necesario verificar disponibilidad, licencia, fecha, granularidad y existencia de tiempos por viaje. No descargué ni evalué conjuntos de esos portales para esta entrega, por lo que no afirmo que proporcionen todas las variables requeridas.

Fuente utilizada

Construí una muestra académica sintética de 600 viajes con generar_datos.py, semilla 42. El CSV viajes_simulados.csv es la fuente efectiva del modelo. No contiene datos personales ni observaciones reales. Esta elección permite demostrar el flujo reproducible mientras no se cuente con una fuente real verificada.

Diccionario de variables

id_viaje: identificador único 1–600, excluido del entrenamiento. distancia_km: 2–25 km simulados. paradas: entero de 3–24. hora_pico: 0=no, 1=sí. lluvia: 0=no, 1=sí. ocupacion_pct: entero de 15–100 %. transbordos: entero de 0–2. tiempo_min: etiqueta numérica positiva que el modelo aprende a estimar.

Generación de la etiqueta

tiempo_min = 2 × distancia_km + 0.8 × paradas + 10 × hora_pico + 5 × lluvia + 0.04 × ocupacion_pct + 4 × transbordos + ruido. El ruido es normal con media 0 y desviación estándar 2 minutos. El tiempo se limita a un mínimo de 1 y se redondea a dos decimales. La fórmula es una suposición didáctica, no una relación validada en transporte real.

Calidad y preparación

El lector exige columnas, identificadores únicos, valores numéricos finitos, variables binarias válidas y costos positivos. No imputé datos faltantes: rechacé las entradas inválidas. Utilicé seis atributos como X y tiempo_min como y. Excluí id_viaje y la etiqueta de los predictores. No necesité normalizar los datos para el árbol.

Modelo y metodología

Utilicé DecisionTreeRegressor de Scikit-learn. Los árboles también permiten regresión cuando la etiqueta es continua. Dividí el conjunto aleatoriamente en 80 % para entrenamiento y 20 % para prueba. GridSearchCV compara profundidades 3, 5, 7, 9 o ilimitada, y hojas mínimas de 3, 5 o 10 muestras, mediante cinco particiones de entrenamiento y MAE. Reservé los 120 casos de prueba para la evaluación final.

Limitaciones

El árbol aprende patrones de la fórmula sintética. Las métricas no demuestran rendimiento sobre Bogotá. Generé los atributos de forma independiente, aunque en datos reales pueden estar relacionados. No modelé rutas, cierres, horarios, velocidades reales ni grupos temporales. Con datos reales tendría que considerar una partición temporal o por ruta, evitar fuga de información y volver a validar.

Referencia de apoyo

Palma Méndez, J. T. (2008). Inteligencia artificial: métodos, técnicas y aplicaciones. McGraw-Hill España. Capítulo 17, lectura indicada en la consigna. Documentación técnica: https://scikit-learn.org/stable/modules/tree.html y https://scikit-learn.org/stable/modules/cross_validation.html. No se atribuyen citas textuales ni páginas no consultadas.