Actividad 3 — Métodos de aprendizaje supervisado

Descripción de los datos y del modelo

Laura Lorena Forero Romero
Docente: Sandra Bautista | Grupo: 24082026_C1_202634
Corporación Universitaria Iberoamericana

Problema y relación con la actividad anterior

La actividad 2 calcula rutas a partir de costos conocidos. Esta actividad introduce aprendizaje supervisado para estimar el tiempo de un viaje a partir de sus características. Es un componente complementario: no se integró la predicción al buscador de rutas ni se verificó su uso en una red real.

Fuentes potenciales de datos

Fuentes candidatas son el portal de Datos Abiertos Bogotá (https://datosabiertos.bogota.gov.co/), el portal de Datos Abiertos Colombia (https://www.datos.gov.co/) y publicaciones oficiales de TransMilenio (https://www.transmilenio.gov.co/). Podrían aportar información sobre rutas, estaciones u operación, pero es necesario verificar disponibilidad, licencia, fecha, granularidad y existencia de tiempos por viaje. No se descargaron ni evaluaron conjuntos de esos portales para esta entrega; no se afirma que proporcionen todas las variables requeridas.

Fuente utilizada

Se construyó una muestra académica sintética de 600 viajes con generar_datos.py, semilla 42. El CSV viajes_simulados.csv es la fuente efectiva del modelo. No contiene datos personales ni observaciones reales. Esta elección permite demostrar el flujo reproducible mientras no se cuente con una fuente real verificada.

Diccionario de variables

id_viaje: identificador único 1–600, excluido del entrenamiento. distancia_km: 2–25 km simulados. paradas: entero de 3–24. hora_pico: 0=no, 1=sí. lluvia: 0=no, 1=sí. ocupacion_pct: entero de 15–100 %. transbordos: entero de 0–2. tiempo_min: etiqueta numérica positiva que el modelo aprende a estimar.

Generación de la etiqueta

tiempo_min = 2 × distancia_km + 0.8 × paradas + 10 × hora_pico + 5 × lluvia + 0.04 × ocupacion_pct + 4 × transbordos + ruido. El ruido es normal con media 0 y desviación estándar 2 minutos. El tiempo se limita a un mínimo de 1 y se redondea a dos decimales. La fórmula es una suposición didáctica, no una relación validada en transporte real.

Calidad y preparación

El lector exige columnas, identificadores únicos, valores numéricos finitos, variables binarias válidas y costos positivos. No se imputan datos faltantes: se rechazan entradas inválidas. Se usan seis atributos como X y tiempo_min como y. No se incluyen id_viaje ni la etiqueta entre los predictores. No se necesita normalización para el árbol.

Modelo y metodología

Se utiliza DecisionTreeRegressor de Scikit-learn. Los árboles también permiten regresión cuando la etiqueta es continua. El conjunto se divide aleatoriamente en 80 % entrenamiento y 20 % prueba. GridSearchCV compara profundidades 3, 5, 7, 9 o ilimitada, y hojas mínimas de 3, 5 o 10 muestras, mediante cinco particiones de entrenamiento y MAE. Los 120 casos de prueba quedan reservados para evaluación final.

Limitaciones

El árbol aprende patrones de la fórmula sintética. Las métricas no demuestran rendimiento sobre Bogotá. Los atributos se generaron de forma independiente, aunque en datos reales pueden estar relacionados. No se modelan rutas, cierres, horarios, velocidades reales ni grupos temporales. Con datos reales se debe considerar una partición temporal o por ruta, evitar fuga de información y volver a validar.

Referencia de apoyo

Palma Méndez, J. T. (2008). Inteligencia artificial: métodos, técnicas y aplicaciones. McGraw-Hill España. Capítulo 17, lectura indicada en la consigna. Documentación técnica: https://scikit-learn.org/stable/modules/tree.html y https://scikit-learn.org/stable/modules/cross_validation.html. No se atribuyen citas textuales ni páginas no consultadas.