Actividad 4 — Métodos de aprendizaje no supervisado

Descripción de los datos y del componente

Laura Lorena Forero Romero
Docente: Sandra Bautista | Grupo: 24082026_C1_202634
Corporación Universitaria Iberoamericana

Objetivo

Agrupar viajes de transporte con características similares utilizando K-means. A diferencia de la actividad 3, no se predice un tiempo conocido y no se proporcionan clases al algoritmo. Los grupos se calculan a partir de las distancias entre atributos estandarizados.

Fuentes candidatas

Se identifican como candidatos el portal Datos Abiertos Bogotá (https://datosabiertos.bogota.gov.co/), Datos Abiertos Colombia (https://www.datos.gov.co/) y publicaciones de TransMilenio (https://www.transmilenio.gov.co/). Antes de usarlos se necesita verificar variables, acceso, licencia, periodo y granularidad. No se descargaron ni evaluaron datos reales de esos portales en este proyecto.

Fuente efectivamente utilizada

Se reutilizan las características de los 600 viajes sintéticos de la actividad 3, generados con semilla 42. preparar_datos.py elimina tiempo_min y conserva únicamente el identificador y seis atributos. El archivo entregado es datos/viajes_sin_etiquetas.csv. Es una muestra académica, no una captura de viajes reales ni una base de usuarios.

Diccionario de datos

id_viaje: identificador único, excluido del modelo. distancia_km: número de 2 a 25 km. paradas: entero de 3 a 24. hora_pico: 0=no, 1=sí. lluvia: 0=no, 1=sí. ocupacion_pct: porcentaje entero de 15 a 100. transbordos: entero de 0 a 2. No existe una etiqueta objetivo ni una clase asignada de antemano.

Preparación y validación

Se exigen columnas, identificadores únicos, valores numéricos finitos y rangos válidos. Se rechazan datos inválidos, sin imputación. StandardScaler resta la media y divide por la desviación estándar de cada atributo. Así las unidades de ocupación o distancia no dominan automáticamente la distancia euclidiana. La estandarización también influye en el peso de los atributos binarios.

Método

K-means minimiza la suma de distancias cuadráticas a los centroides. Se prueban 2 a 6 grupos, con semilla 42 y 20 inicializaciones por candidato. La selección utiliza la mayor silueta. Su rango es de -1 a 1; un valor cercano a cero indica separación limitada. La inercia suele disminuir al aumentar k y por sí sola no determina el mejor número de grupos.

Interpretación y límites

Se eligieron 4 grupos con silueta 0.2004. La separación es limitada. Los cuatro grupos coinciden principalmente con las combinaciones de hora pico y lluvia, lo que refleja el efecto de esas variables binarias tras escalar. Los demás atributos se generaron de forma independiente y no representan segmentos operativos naturales. Los números de grupo son arbitrarios, no jerarquías de calidad.

Alcance de la evaluación

Se agrupa y evalúa la misma muestra con una medida interna; no hay precisión de clasificación porque no hay etiquetas verdaderas. Tampoco hay prueba externa de generalización. La reproducibilidad con semilla fija no demuestra estabilidad con otras muestras o semillas. Con datos reales se deberían estudiar estabilidad, pertinencia de atributos, métodos alternativos y utilidad de los grupos.

Referencia de apoyo

Palma Méndez, J. T. (2008). Inteligencia artificial: métodos, técnicas y aplicaciones. McGraw-Hill España. Capítulo 16, lectura indicada en la actividad. Documentación técnica de Scikit-learn: https://scikit-learn.org/stable/modules/clustering.html y https://scikit-learn.org/stable/modules/generated/sklearn.preprocessing.StandardScaler.html. No se incluyen citas textuales ni páginas no consultadas.